PCA vs Kernel PCA

Παντελή Μπαλλή

5/01/2025

Περίληψη

Η εργασία εξετάζει τη σύγκριση μεταξύ της κλασικής Ανάλυσης Κύριων Συνιστωσών (PCA) και της επέκτασής της μέσω πυρήνων (Kernel PCA), που στοχεύει στη μείωση διαστάσεων δεδομένων με γραμμικές και μη γραμμικές σχέσεις. Παρουσιάζονται τα βασικά χαρακτηριστικά και η εφαρμογή διαφορετικών πυρήνων (π.χ. πολυωνυμικός, RBF, sigmoid) στο σύνολο δεδομένων Iris. Τα αποτελέσματα καταδεικνύουν ότι η Kernel PCA επιτυγχάνει καλύτερη αναπαράσταση των δεδομένων σε μη γραμμικά προβλήματα, ενώ η κλασική PCA υπερτερεί σε ταχύτητα. Συμπεραίνεται ότι η επιλογή της μεθόδου εξαρτάται από τις απαιτήσεις του προβλήματος, με την Kernel PCA να προσφέρει μεγαλύτερη ευελιξία και ισχύ ανάλυσης σε πιο σύνθετα δεδομένα.

Εισαγωγή

Η Ανάλυση Κύριων Συνιστωσών (Principal Component Analysis - PCA) είναι μία από τις θεμελιώδεις τεχνικές μείωσης διαστάσεων και χρησιμοποιείται ευρέως στη στατιστική και τη μηχανική μάθηση. Αναπτύχθηκε το 1901 από τον Karl Pearson και επιτρέπει τη μείωση της διάστασης των δεδομένων με τη διατήρηση των πιο σημαντικών χαρακτηριστικών τους, μεγιστοποιώντας τη διακύμανση στο μειωμένο χώρο.

Παρά την ευρεία εφαρμογή της, η PCA έχει έναν σημαντικό περιορισμό: βασίζεται στη γραμμικότητα των δεδομένων. Αυτό την καθιστά λιγότερο αποτελεσματική όταν τα δεδομένα έχουν μη γραμμική φύση. Για την αντιμετώπιση αυτού του περιορισμού, αναπτύχθηκε η Kernel PCA, η οποία επεκτείνει την PCA με τη χρήση μη γραμμικών πυρήνων. Μετασχηματίζει τα δεδομένα σε έναν χώρο υψηλότερων διαστάσεων, όπου μπορούν να αποκαλυφθούν πιο πολύπλοκα πρότυπα και δομές.

Και οι δύο μέθοδοι είναι χρήσιμες σε πλήθος εφαρμογών, όπως η οπτικοποίηση δεδομένων, η προεπεξεργασία και η αναγνώριση προτύπων. Στην εργασία αυτή, εξετάζουμε τα χαρακτηριστικά και τις διαφορές τους, καθώς και την απόδοσή τους σε διαφορετικού τύπου σύνολα δεδομένων.

Αλγόριθμος **PCA**

Η Ανάλυση Κύριων Συνιστωσών (PCA) είναι μια διαδικασία που επιδιώκει να μειώσει τη διάσταση ενός συνόλου δεδομένων, διατηρώντας τη μέγιστη δυνατή πληροφορία. Ακολουθεί η αναλυτική περιγραφή των βημάτων της διαδικασίας:

1. Υπολογισμός του μέσου όρου των δεδομένων:

Για ένα σύνολο δεδομένων $X = \{x_1, x_2, \ldots, x_N\}$, όπου κάθε $x_i \in R^D$, υπολογίζεται ο μέσος όρος:

$$\bar{x} = \frac{1}{N} \sum_{i=1}^{N} x_i.$$

Αυτός ο μέσος όρος χρησιμοποιείται για την κεντροποίηση των δεδομένων, μετακινώντας τα δεδομένα έτσι ώστε το ”κέντρο μάζας” τους να βρίσκεται στην αρχή του χώρου.

2. Τυποποίηση των δεδομένων αν είναι αναγκαίο:

   Αν οι μεταβλητές έχουν διαφορετικές μονάδες μέτρησης ή κλίμακες, είναι απαραίτητο να τις τυποποιησουμε ώστε να έχουν ίδια κλίμακα μονάδας. Έστω και μία μεταβλητή να έχει διαφορετική μονάδα είναι απαραίτητη η τυποποίηση καθώς θα έχει μεγαλύτερη επίδραση.

$$dx_i = \frac{x_i - \bar{x}}{s^2}, \quad \forall i \in \{1, 2, \ldots, N\}.$$

3. Υπολογισμός του πίνακα συνδιακύμανσης:

   Ο πίνακας συνδιακύμανσης Σ περιγράφει τη διασπορά και τις αλληλεξαρτήσεις μεταξύ των μεταβλητών και υπολογίζεται ως εξής:

$$\Sigma = \frac{1}{N} \sum_{i=1}^{N} dx_i dx_i^T,$$

   όπου Σ είναι ένας συμμετρικός, τετραγωνικός πίνακας διαστάσεων $D \times D$.

4. Υπολογισμός ιδιοτιμών και ιδιοδιανυσμάτων:

   Επιλύουμε την εξίσωση ιδιοτιμών του πίνακα συνδιακύμανσης:

$$\Sigma u_k = \lambda_k u_k,$$

   όπου u_k είναι τα ιδιοδιανύσματα (κατευθύνσεις μέγιστης διακύμανσης) και λ_k οι αντίστοιχες ιδιοτιμές (μεγέθη της διακύμανσης στις κατευθύνσεις αυτές).

5. Ταξινόμηση των ιδιοτιμών:

   Οι ιδιοτιμές λ_k ταξινομούνται κατά φθίνουσα σειρά. Οι μεγαλύτερες ιδιοτιμές αντιπροσωπεύουν τις διαστάσεις με τη μεγαλύτερη διακύμανση και τη σημαντικότερη πληροφορία.

6. Επιλογή κύριων συνιστωσών:

   Αφουύ έχουμε υπολογίσει πρώτα τις ιδιοτιμές $\lambda_1, \lambda_2, \ldots, \lambda_d$ και τα αντίστοιχα ιδιοδιανύσματα $v_1, v_2, \ldots, v_d$ του πίνακα συνδιακύμανσης Σ. Οι κύριες συνιστώσες ορίζονται ως γραμμικοί συνδυασμοί των δεδομένων στις κατευθύνσεις των ιδιοδιανυσμάτων.

   Η πρώτη κύρια συνιστώσα (PC1) δίνεται από:

$$\mathrm{PC1} = X' v_1,$$

   όπου X' είναι τα τυποποιημένα δεδομένα.

   Η δεύτερη κύρια συνιστώσα (PC2) είναι:

$$\mathrm{PC2} = X' v_2,$$

   και ούτω καθεξής.

   Κάθε κύρια συνιστώσα είναι ορθογώνια προς τις υπόλοιπες, και η διακύμανση που εξηγεί ισούται με την αντίστοιχη ιδιοτιμή της, δηλαδή:

$$\mathrm{Var}(\mathrm{PCi}) = \lambda_i.$$

Η επιλογή του αριθμού k των κύριων συνιστωσών στο PCA βασίζεται σε διάφορα κριτήρια. Οι πιο συνηθισμένες μέθοδοι είναι: (1) η επιλογή k έτσι ώστε να εξηγείται ένα προκαθορισμένο ποσοστό της συνολικής διακύμανσης (π.χ., 80% ή 95%), (2) το κριτήριο του Kaiser, όπου διατηρούνται οι συνιστώσες με ιδιοτιμές μεγαλύτερες από τη μέση ιδιοτιμή, και (3) το Scree Plot, το οποίο εντοπίζει το σημείο ”αγκύλης” όπου η πτώση των ιδιοτιμών γίνεται πιο σταδιακή. ΄Αλλες μέθοδοι περιλαμβάνουν τη μέθοδο του σπασμένου ραβδιού, τη μέθοδο Velicer, ελέγχους υποθέσεων, καθώς και στατιστικές προσεγγίσεις. Ιδιαίτερη αναφορά αξίζουν η μέθοδος bootstrap και η Cross-Validation, οι οποίες προσφέρουν αξιόπιστα αποτελέσματα. Η μέθοδος bootstrap επιτρέπει την εκτίμηση διαστημάτων εμπιστοσύνης για τις ιδιοτιμές, ενώ η Cross-Validation παρέχει μία επαναληπτική αξιολόγηση που διασφαλίζει τη γενίκευση των αποτελεσμάτων. Οι παραπάνω μέθοδοι μπορούν να χρησιμοποιηθούν συνδυαστικά ανάλογα με τις απαιτήσεις του προβλήματος.

0.1 Κατασκευή του Πίνακα Πυρήνα

Ας υποθέσουμε ότι έχουμε έναν μη γραμμικό μετασχηματισμό $\phi(x)$ από τον αρχικό D-διάστατο χώρο χαρακτηριστικών σε έναν M-διάστατο χώρο χαρακτηριστικών, όπου συνήθως $M \gg D$. Με αυτόν τον τρόπο, κάθε σημείο δεδομένων $\mathbf{x}_i$ προβάλλεται σε ένα σημείο $\phi(x_i)$. Μπορούμε να εφαρμόσουμε την κλασική PCA στον νέο χώρο χαρακτηριστικών, αλλά αυτό μπορεί να είναι εξαιρετικά δαπανηρό και αναποτελεσματικό υπολογιστικά. Ευτυχώς, μπορούμε να χρησιμοποιήσουμε μεθόδους πυρήνα (kernel methods) για να απλοποιήσουμε τον υπολογισμό **??**.

Αρχικά, υποθέτουμε ότι έχουμε τυποποιήσει ή κεντροποιήσει τα δεδομένα μας με σκοπό να έχουν μέσο όρο μηδέν.Με αυτόν τον τρόπο και για την κατασκευή του πυρήνα μας θα ισχύει:

$$\frac{1}{N}\sum_{i=1}^{N}\phi(x_i) = 0.$$

Έτσι ο πίνακας συνδιακύμανσης υπολογίζεται ως:

$$\mathbf{C} = \frac{1}{N}\sum_{i=1}^{N}\phi(x_i)\phi(x_i)^{\top}. \tag{1}$$

Όπου θα είναι ενας πίνακας $M \times M$.

Οι ιδιοτιμές και τα ιδιοδιανύσματα δίνονται από την εξίσωση:

$$\mathbf{C}\mathbf{v}_k = \lambda_k \mathbf{v}_k, \tag{2}$$

όπου $k = 1, 2, \ldots, M$.

Από τις εξισώσεις (1) και (2), έχουμε:

$$\frac{1}{N}\sum_{i=1}^{N}\phi(x_i)\ \phi(x_i)^{\top}\mathbf{v}_k = \lambda_k \mathbf{v}_k \tag{3}$$

Αυτό μπορεί να ξαναγραφεί ως:

$$\mathbf{v}_k = \sum_{i=1}^{N} a_{ki}\phi(x_i). \tag{4}$$

Αντικαθιστώντας την εξίσωση (4) στην εξίσωση (3), προκύπτει:

$$\frac{1}{N}\sum_{i=1}^{N}\phi(x_i)\phi(x_i)^{\top}\sum_{j=1}^{N} a_{kj}\phi(x_j) = \lambda_k \sum_{i=1}^{N} a_{ki}\phi(x_i).$$

Εάν ορίσουμε τη συνάρτηση πυρήνα ως:

$$\kappa(x_i, x_j) = \phi(x_i)^\top \phi(x_j), \tag{5}$$

Αν πολλαπλασιάσουμε και τις δύο πλευρές της Εξίσωσης (5) με $\phi(x_i)^\top$, έχουμε:

$$\frac{1}{N} \sum_{i=1}^{N} \kappa(x_i, x_j) \sum_{j=1}^{N} a_{kj} \kappa(x_i, x_j) = \lambda_k \sum_{i=1}^{N} a_{ki} \kappa(x_i, x_j). \tag{6}$$

Μπορούμε να γραφεί με συμβολισμό πινάκων ως:

$$\mathbf{K}^2 \mathbf{a}_k = \lambda_k N \mathbf{K} \mathbf{a}_k, \tag{7}$$

όπου:

$$K_{i,j} = \kappa(x_i, x_j), \tag{8}$$

και $\mathbf{a}_k$ είναι το N-διάστατο διάνυσμα στήλης με στοιχεία a_{ik} για $i = 1, 2, \ldots, M$.Μπορούμε να βρούμε λύσεις για a_i επιλύοντας το ακόλουθο πρόβλημα ιδιοτιμών :

$$\mathbf{K} \mathbf{a}_k = \lambda_k N \mathbf{a}_k, \tag{9}$$

και οι αντίστοιχες πυρηνικές κύριες συνιστώσες μπορούν να υπολογιστούν ως:

$$y_k(x) = \phi(x)^\top \mathbf{v}_k = \sum_{i=1}^{N} a_{ki} \kappa(x, x_i). \tag{10}$$

Αν το σύνολο δεδομένων $\{\phi(x_i)\}$ δεν έχει μηδενικό μέσο όρο, μπορούμε να χρησιμοποιήσουμε τον πίνακα Gram $\tilde{\mathbf{K}}$ για να αντικαταστήσουμε τον πυρήνα πίνακα $\mathbf{K}$. Ο πίνακας Gram ορίζεται ως:

$$\tilde{\mathbf{K}} = \mathbf{K} - \mathbf{1}_N \mathbf{K} - \mathbf{K} \mathbf{1}_N + \mathbf{1}_N \mathbf{K} \mathbf{1}_N, \tag{11}$$

όπου $\mathbf{1}_N$ είναι ο πίνακας $N \times N$ με όλα τα στοιχεία ίσα με $1/N$ ΄Οπως αναφέρεται στο [Bishop, 2006].

Το πλεονέκτημα των μεθόδων πυρήνα είναι ότι δεν χρειάζεται να υπολογίζουμε ρητά τη $\phi(x_i)$. Μπορούμε να κατασκευάσουμε απευθείας τον πίνακα πυρήνα από τα δεδομένα εκπαίδευσης $\{x_i\}$ και έπειτα να τον χρησιμοποιήσουμε για να προσδιορίσουμε τις ιδιοτιμές και τα ιδιοδιανύσματα. Δύο συνήθως χρησιμοποιούμενοι

πυρήνες είναι ο πολυωνυμικός πυρήνας.

$$\kappa(\mathbf{x}, \mathbf{y}) = (\mathbf{x}^\top \mathbf{y})^d, \tag{12}$$

ή

$$\kappa(\mathbf{x}, \mathbf{y}) = (\mathbf{x}^\top \mathbf{y} + c)^d, \tag{13}$$

όπου $c > 0$ είναι μια σταθερά, και ο Gaussian πυρήνας:

$$\kappa(\mathbf{x}, \mathbf{y}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{y}\|^2}{2\sigma^2}\right), \tag{14}$$

με παράμετρο σ.

Οι συναρτήσεις kernel, όπως το RBF (Radial Basis Function) ή το polynomial kernel, εξαρτώνται από τις αποστάσεις μεταξύ των δεδομένων. Αν τα χαρακτηριστικά σου δεν είναι στην ίδια κλίμακα, κάποια χαρακτηριστικά μπορεί να έχουν δυσανάλογη επιρροή στο αποτέλεσμα

1 Εφαρμογή PCA και Kernel PCA στο Dataset Iris

Το *dataset Iris* είναι ένα από τα πιο διαδεδομένα σύνολα δεδομένων στη μηχανική μάθηση και την ανάλυση δεδομένων. Παρέχει ένα εξαιρετικό παράδειγμα για την επίδειξη τεχνικών μείωσης διαστάσεων, όπως η Kernel PCA, λόγω της απλότητας, της ισορροπημένης κατανομής κλάσεων και της μικρής του διάστασης.

Το dataset αποτελείται από 150 δείγματα, κατανεμημένα ισομερώς σε τρεις κατηγορίες φυτών της ίριδας: *Setosa*, *Versicolor*, και *Virginica*. Κάθε δείγμα περιλαμβάνει τέσσερα χαρακτηριστικά:

- Μήκος του κάλυκα (sepal length),
- Πλάτος του κάλυκα (sepal width),
- Μήκος του πετάλου (petal length),
- Πλάτος του πετάλου (petal width).

Η εφαρμογή PCA και Kernel PCA στο dataset Iris περιλαμβάνει τη χρήση διαφόρων πυρήνων. Οι συναρτήσεις πυρήνα που χρησιμοποιούνται είναι οι εξής:

RBF Kernel

$$\kappa(x, y) = \exp \quad -\frac{\|x - y\|^2}{2\sigma^2}$$

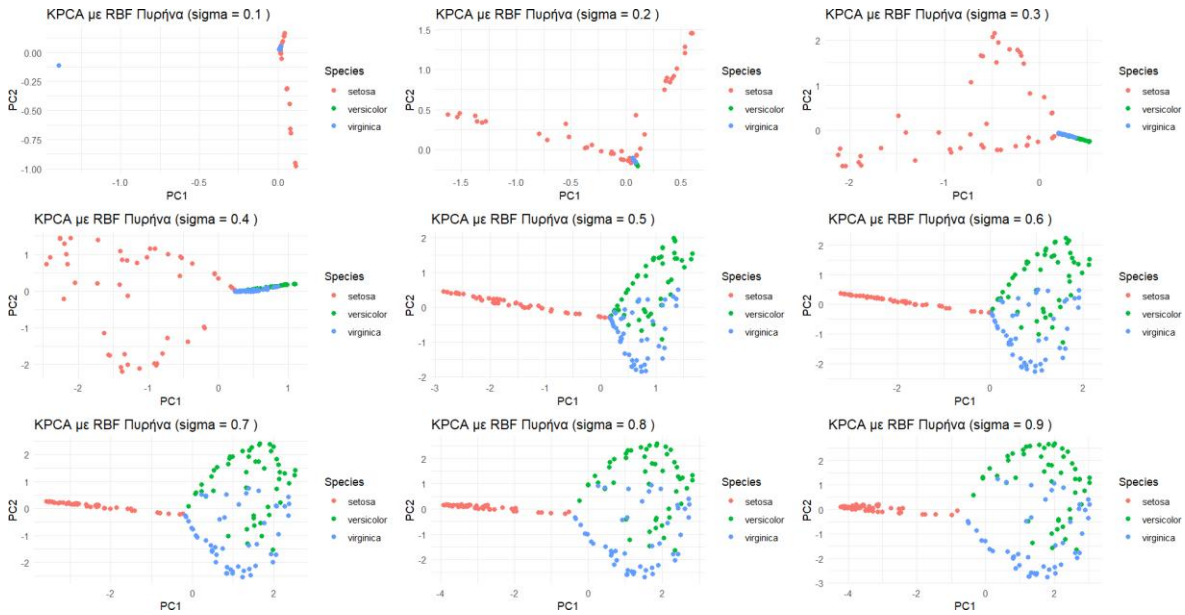

Σχήμα 1: Kernel PCA με RBF Kernel

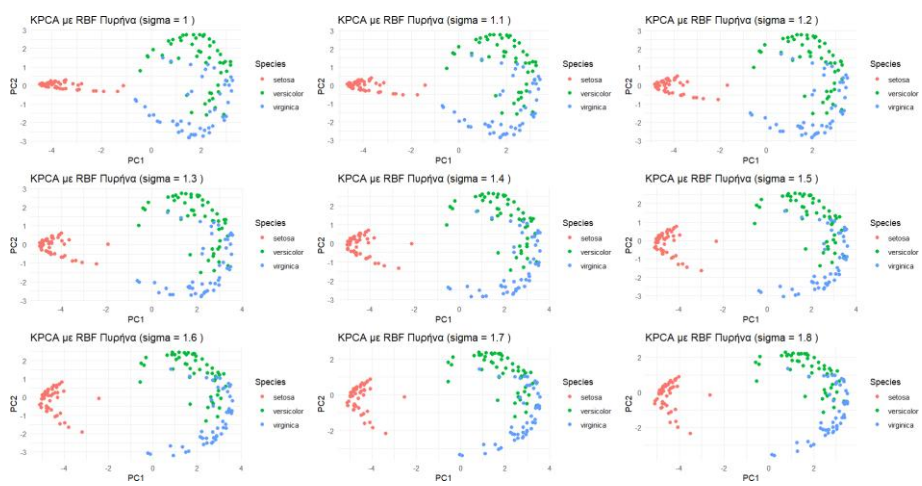

Σχήμα 2: Kernel PCA με RBF Kernel

Ο RBF πυρήνας αποδεικνύεται εξαιρετικά αποτελεσματικός για τη μη γραμμική απεικόνιση των δεδομένων, με την παράμετρο σ να διαδραματίζει καθοριστικό ρόλο στον διαχωρισμό των κατηγοριών. Για χαμηλές τιμές σ (π.χ., 0.1 - 0.4), η επίδραση της μη γραμμικότητας είναι περιορισμένη, με αποτέλεσμα οι κατηγορίες να εμφανίζονται ανεπαρκώς διαχωρισμένες. Στη συνέχεια, με μέτριες τιμές σ (0.5 - 1.2), παρατηρείται σημαντική βελτίωση στον διαχωρισμό, ιδίως για $\sigma = 1.0 - 1.2$, όπου ο διαχωρισμός μεταξύ των κατηγοριών *Setosa*, *Versicolor*, και *Virginica* είναι σαφής και διατηρείται η δομή των δεδομένων. Ωστόσο, όταν σ ξεπερνά το 1.5, η υπερβολική ομαλότητα στη συνάρτηση πυρήνα οδηγεί σε μείωση της διακριτικής ικανότητας, με τις κατηγορίες να πλησιάζουν και να συγχωνεύονται σταδιακά.

Συνολικά, οι τιμές σ μεταξύ 0.7 και 1.2 φαίνεται να επιτυγχάνουν την καλύτερη ισορροπία, αναδεικνύοντας τον RBF πυρήνα ως κατάλληλη επιλογή για τη μη γραμμική ανάλυση των δεδομένων.

Polynomial Kernel

$$\kappa(x, y) = (x^\top y + c)^d, \quad c > 0$$

Ο Πολυωνυμικός Πυρήνας αποτελεί μια ευέλικτη επιλογή για τον Kernel PCA, επιτρέποντας τον μη γραμμικό διαχωρισμό των δεδομένων μέσω παραμετροποίησης των μεταβλητών degree, gamma, και coef0. ΄Οπως φαίνεται από τα διαγράμματα, ο βαθμός του πολυωνύμου (degree) επηρεάζει την πολυπλοκότητα του μοντέλου. ΄Οταν το degree είναι 2, το μοντέλο έχει πιο περιορισμένη πολυπλοκότητα, με τον διαχωρισμό των κατηγοριών να είναι λιγότερο ευδιάκριτος. Αντίθετα, για degree = 3, οι διαχωριστικές γραμμές γίνονται πιο καμπύλες, βελτιώνοντας τον διαχωρισμό, ειδικά μεταξύ των κατηγοριών versicolor και virginica. Η παράμετρος gamma καθορίζει την ευαισθησία του πυρήνα στις αποστάσεις μεταξύ των σημείων. Χαμηλές τιμές του gamma (π.χ., 0.1) οδηγούν σε πιο ”απλωμένες” κατηγορίες, ενώ υψηλότερες τιμές (π.χ., 0.5 ή 1.0) προσφέρουν σαφέστερο διαχωρισμό. Η παράμετρος coef0 επιδρά στη μετατόπιση του πολυωνύμου, με μεγαλύτερες τιμές να βελτιώνουν την προσαρμογή σε ορισμένες περιπτώσεις. Συνολικά, οι συνδυασμοί degree = 3, gamma = 0.5, coef0 = 0 και degree = 3, gamma = 0.5, coef0 = 1 φαίνονται να επιτυγχάνουν τον καλύτερο διαχωρισμό των κατηγοριών

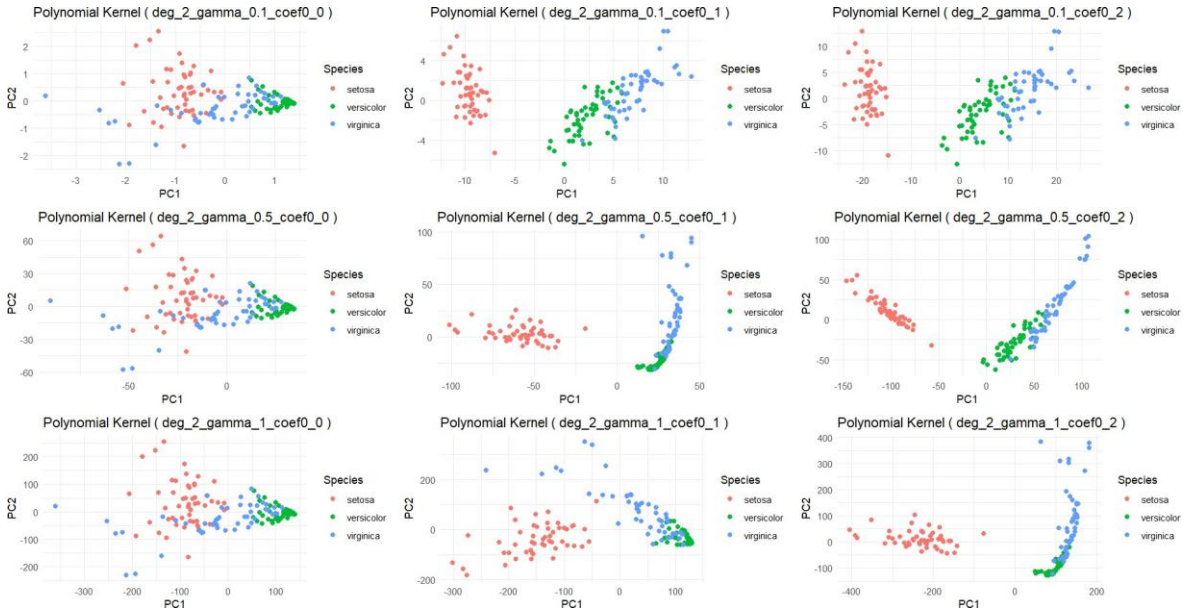

Σχήμα 3: Kernel PCA με Polynomial Kernel .

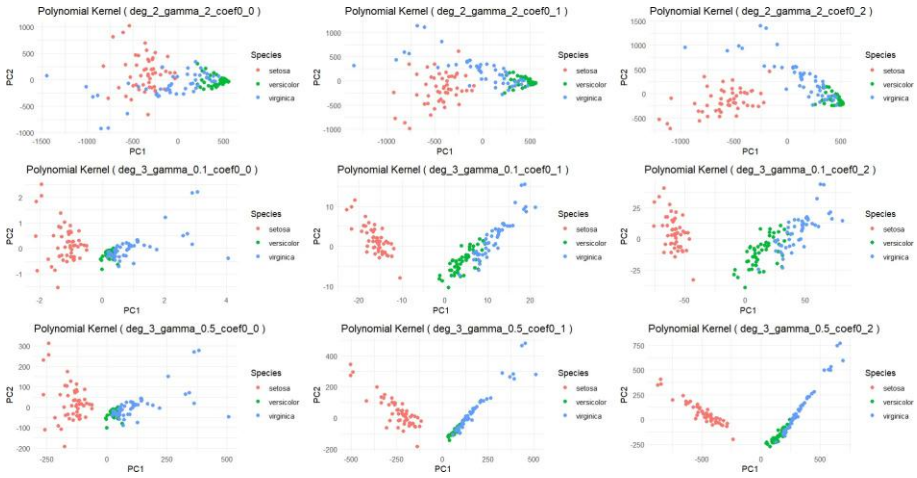

Σχήμα 4: Kernel PCA με Polynomial Kernel .

Sigmoid Kernel

$$\kappa(x, y) = \tanh(\alpha x^{\top} y + c), \quad \alpha > 0,\ c > 0$$

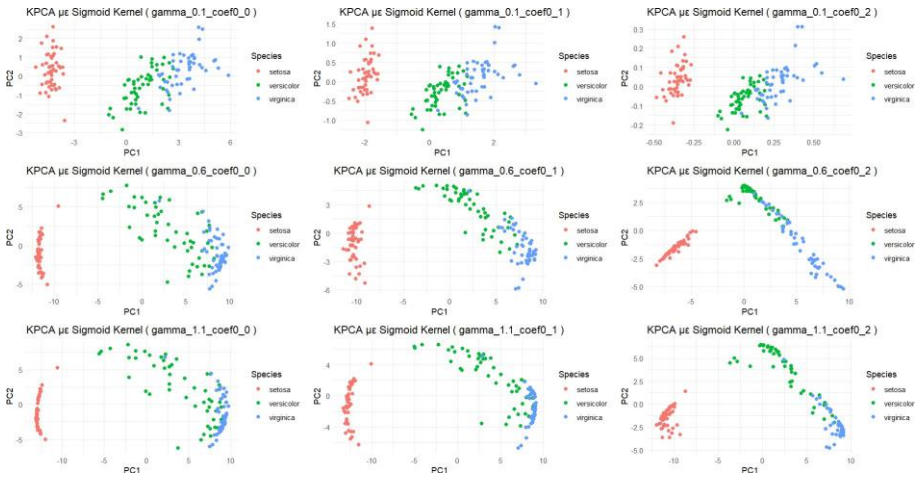

Σχήμα 5: Kernel PCA με Sigmoid Kernel .

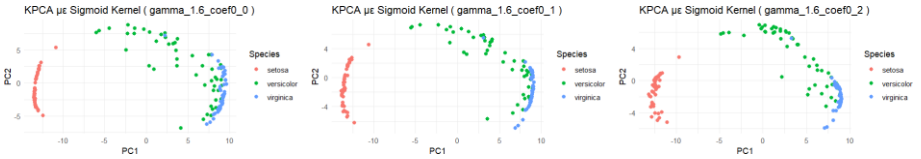

Σχήμα 6: Kernel PCA με Sigmoid Kernel .

Ο Sigmoid Πυρήνας προσφέρει έναν μη γραμμικό μετασχηματισμό των δεδομένων, με την απόδοσή του να επηρεάζεται σημαντικά από τις παραμέτρους gamma και coef0. Όπως φαίνεται από τα διαγράμματα, χαμηλές τιμές του gamma (π.χ., 0.1) παρέχουν περιορισμένη ευαισθησία στη μη γραμμικότητα, με αποτέλεσμα οι κατηγορίες να μην διαχωρίζονται επαρκώς. Καθώς το gamma αυξάνεται (π.χ., 0.6 - 1.6), παρατηρείται σαφέστερος διαχωρισμός των κατηγοριών, ιδίως μεταξύ versicolor και virginica, ενώ η κατηγορία setosa διατηρεί τον πλήρη διαχωρισμό της σε όλες τις περιπτώσεις. Η παράμετρος coef0 επηρεάζει τη μετατόπιση της συνάρτησης, με μεγαλύτερες τιμές (π.χ., 1 ή 2) να προσφέρουν μεγαλύτερη διαφοροποίηση, αλλά ταυτόχρονα να αυξάνουν την πολυπλοκότητα. Ο συνδυασμός gamma = 0.6 - 1.1 και coef0 = 1 φαίνεται να προσφέρει τη βέλτιστη ισορροπία μεταξύ διαχωρισμού και απεικόνισης της δομής των δεδομένων.

PCA

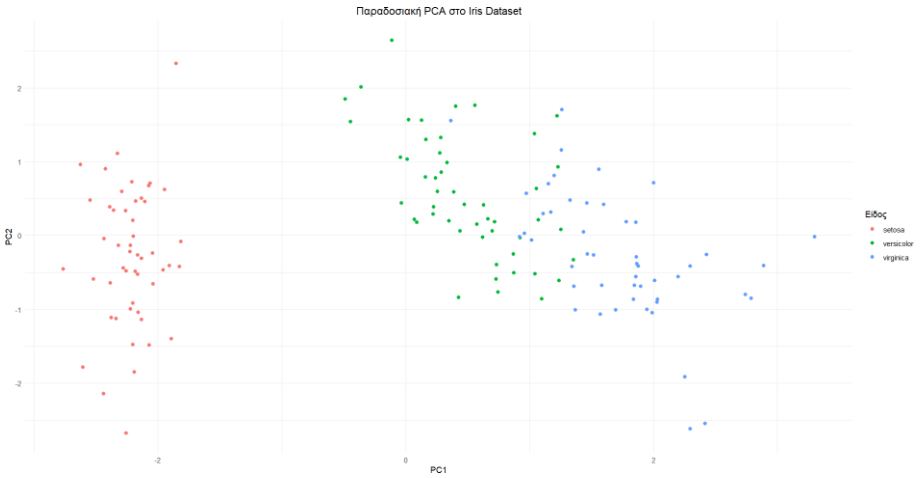

Σχήμα 7: PCA με τυποποιημένα δεδομένα.

Σύνοψη

Η Παραδοσιακή PCA είναι μια απλή και αποτελεσματική μέθοδος για γραμμική μείωση διαστάσεων, αλλά παρουσιάζει περιορισμούς όταν τα δεδομένα δεν είναι γραμμικά διαχωρίσιμα. Στην περίπτωση του συνόλου Iris, η PCA καταφέρνει να διαχωρίσει σαφώς την κατηγορία *Setosa*, ενώ οι κατηγορίες *Versicolor* και *Virginica* επικαλύπτονται σημαντικά.

Αντίθετα, η Kernel PCA με μη γραμμικούς πυρήνες, όπως ο RBF, ο Πολυωνυμικός, και ο Sigmoid, επιτυγχάνει πολύ καλύτερα αποτελέσματα, αξιοποιώντας τη μη γραμμική δομή των δεδομένων. Ο RBF πυρήνας ξεχωρίζει ως η βέλτιστη επιλογή, ιδιαίτερα για τιμές $\sigma = 0.7-1.2$, προσφέροντας πλήρη και ισορροπημένο διαχωρισμό μεταξύ των κατηγοριών. Ο Πολυωνυμικός πυρήνας επίσης αποδίδει καλά, με τις κατάλληλες παραμέτρους (π.χ., degree = 3, gamma = 0.5), ενώ ο Sigmoid πυρήνας είναι λιγότερο αποτελεσματικός και πιο ευαίσθητος στην παραμετροποίηση.

Συνολικά, η Kernel PCA με RBF πυρήνα αποδεικνύεται η καταλληλότερη μέθοδος για τη συγκεκριμένη ανάλυση, προσφέροντας τον βέλτιστο διαχωρισμό των κατηγοριών και αναδεικνύοντας τη δύναμη της μη γραμμικής μείωσης διαστάσεων.